

# 실험 방법론

## AWS SageMaker 기반 SAC 전기차 에너지 효율 최적화 실험 방법론

### 1. 실험 설계 및 연구 방법론

#### 1.1 연구 목적 및 가설

본 연구는 SAC(Soft Actor-Critic) 강화학습 알고리즘을 활용하여 전기차의 에너지 효율을 최적화하는 것을 목적으로 한다. 구체적으로 순수 학습과 전이 학습의 성능을 비교 분석하며, 기존 크루즈 모드 대비 개선 효과를 검증한다.

연구 가설:

- H1: 전이학습 SAC > 순수학습 SAC > 크루즈 모드 (에너지 효율 측면)
- H2: 전이학습 SAC가 더 빠른 수렴 속도를 보임
- H3: 두 SAC 모델 모두 크루즈 모드 대비 20% 이상 효율 개선
- H4: 전이학습이 학습 초기 안정성에서 우수함

#### 1.2 실험 설계 구조

- \*삼중 비교 설계(Three-arm Comparison Design)\*\*를 채택하여 공정한 성능 비교를 수행한다.
- **기준선(Baseline):** 크루즈 모드 - PID 제어 기반 일정 속도(60km/h) 유지
- **실험군 1:** SAC from Scratch - 순수 강화학습으로 처음부터 학습
- **실험군 2:** SAC Transfer Learning - 사전학습 모델을 전기차 환경에 적응

#### 1.3 실험 환경 설정

클라우드 기반 분산 실험으로 재현성과 확장성을 보장한다.

- **플랫폼:** AWS SageMaker Training Jobs
- **병렬 처리:** 두 SAC 모델을 동시 훈련하여 환경 조건 통제
- **자동화:** 실험 추적, 성능 평가, 결과 분석의 완전 자동화

### 2. 데이터 준비 및 전처리 방법론

## 2.1 전처리된 데이터 활용 근거

기존에 수행된 출퇴근 분리 전처리를 활용하여 실험의 현실성과 정확성을 높인다.

활용 데이터:

- **훈련 데이터:** rush\_separated\_train\_corrected\_\*.csv (1-9월 데이터)
- **테스트 데이터:** rush\_separated\_test\_corrected\_\*.csv (10-12월 데이터)
- **정규화 정보:** rush\_normalization\_corrected\_\*.json

## 2.2 상태 공간 설계

26차원 확장 상태벡터를 통해 복잡한 주행 환경을 정밀하게 모델링한다.

상태 벡터 구성:

- **시간 특성 (7차원):** 정규화된 시간/월, 주기성, 시간대 분류
- **교통 특성 (4차원):** 시간대별 정규화된 교통량, 방향 정보
- **기상 특성 (8차원):** 온도/습도/풍속/강수, 도로/시정 상태
- **도로 특성 (5차원):** 경사도, 난이도 점수, 요일/시간대 분류
- **출퇴근 분류 (2차원):** 아침 출근/저녁 퇴근 여부

## 2.3 보상 함수 설계

시간대별 특화 보상함수를 적용하여 출퇴근 패턴 차이를 반영한다.

보상 구조:

- **에너지 효율:** 주 목적 함수로 60% 가중치
- **속도 추종:** 목표 속도 유지를 위한 30% 가중치
- **승차감:** 가속도 변화를 통한 10% 가중치
- **시간대 조정:** 저녁 출퇴근 시 1.05배 가중치 적용

# 3. AWS SageMaker 기반 실험 인프라

## 3.1 클라우드 MLOps 파이프라인 설계

완전 자동화된 머신러닝 운영 체계를 구축하여 실험의 재현성과 확장성을 보장한다.

인프라 구성:

- **Experiments:** 실험 추적 및 메타데이터 관리

- **Training Jobs:** 분산 병렬 훈련 실행
- **Model Registry:** 훈련된 모델 버전 관리
- **Endpoints:** 실시간 추론 서비스 배포

### 3.2 리소스 최적화 전략

비용 효율적 클라우드 활용을 위한 다층 최적화를 적용한다.

최적화 방법:

- **Spot Instances:** 70% 비용 절감을 위한 스팟 인스턴스 활용
- **Auto Scaling:** 유휴 리소스 자동 제거
- **Early Stopping:** 수렴 조건 달성 시 자동 훈련 종료
- **Resource Monitoring:** 실시간 비용 추적 및 알림

### 3.3 실험 재현성 보장

과학적 엄밀성을 위한 완전 재현 가능한 실험 환경을 구성한다.

재현성 요소:

- **환경 일관성:** Docker 컨테이너 기반 동일 환경
- **시드 고정:** 랜덤 시드 통제로 결과 재현성 확보
- **버전 관리:** 코드, 데이터, 모델의 완전한 버전 추적
- **실험 로깅:** 모든 하이퍼파라미터와 결과의 자동 기록

## 4. 강화학습 모델 구현 방법론

### 4.1 SAC 알고리즘 선택 근거

연속 제어 환경에 최적화된 SAC(Soft Actor-Critic)를 선택한 이유는 다음과 같다.

기술적 장점:

- **안정성:** 엔트로피 정규화를 통한 학습 안정성 확보
- **샘플 효율성:** 오프-폴리시 학습으로 데이터 효율성 향상
- **연속 제어:** 가속도 제어에 적합한 연속 행동 공간 지원
- **수렴성:** 목표 엔트로피 자동 조정으로 안정적 수렴

### 4.2 전이학습 전략

도메인 적응 기반 전이학습을 통해 학습 효율성을 향상시킨다.

전이학습 프로세스:

1. 사전학습 모델 선택: LunarLanderContinuous-v2 SAC 모델
2. 네트워크 적응: 8차원 → 26차원 상태공간 확장
3. 점진적 Fine-tuning: 낮은 학습률로 도메인 적응
4. 성능 검증: 원본 환경 대비 성능 향상 확인

## 4.3 하이퍼파라미터 최적화

과학적 근거 기반 파라미터 설정으로 최적 성능을 도출한다.

핵심 파라미터:

- 학습률: Actor/Critic 모두  $3e-4$  (SAC 표준)
- 배치 크기: 256 (안정성과 효율성 균형)
- 리플레이 버퍼: 100,000 (충분한 경험 저장)
- 할인 인자: 0.99 (장기 보상 중시)

## 5. 성능 평가 및 분석 방법론

### 5.1 정량적 성능 지표

실험 설계서 5.1절 기준에 따른 체계적 성능 평가를 수행한다.

주요 지표:

- 에너지 효율: 주행거리(km) / 소모전력(kWh)
- SOC 감소율:  $(\text{초기SOC} - \text{최종SOC}) / \text{초기SOC} \times 100$
- 속도 추종률: 목표속도  $\pm 5\text{km/h}$  유지 비율
- 수렴 속도: 목표 성능 90% 도달 에피소드
- 학습 안정성: 보상 변화량 분산

### 5.2 통계적 검정 방법론

과학적 엄밀성을 위한 다층 통계 분석을 적용한다.

분석 단계:

1. 기술통계: 평균, 표준편차, 사분위수, 이상치 탐지

2. 정규성 검정: Shapiro-Wilk 테스트
3. 비교 통계: 대응표본 t-검정, 일원배치 분산분석
4. 효과크기: Cohen's d 계산
5. 사후분석: Tukey HSD 다중비교

## 5.3 시각화 및 해석 전략

논문 게재급 고품질 시각화를 통한 결과 해석을 수행한다.

시각화 구성:

- 학습 곡선: 보상/효율 진행 과정 추적
- 성능 분포: 박스플롯, 바이올린플롯 활용
- 수렴 분석: 수렴 속도 및 안정성 비교
- 상관관계: 히트맵을 통한 지표간 관계 분석

## 6. 실험 실행 프로세스

### 6.1 단계별 실행 절차

체계적 실험 진행을 위한 9단계 프로세스를 수립한다.

#### Phase 1: 환경 준비

1. AWS SageMaker Studio 접속 및 환경 설정
2. 전처리된 데이터 S3 업로드
3. 실험 코드 및 설정 파일 배치

#### Phase 2: 실험 실행

4. SageMaker Experiments 설정 및 Trial 생성
5. PyTorch Estimator 구성 및 하이퍼파라미터 설정
6. 병렬 훈련 작업 시작 (SAC from Scratch + Transfer Learning)

#### Phase 3: 모니터링 및 분석

7. 실시간 훈련 상태 모니터링
8. 훈련 완료 후 결과 다운로드 및 통계 분석
9. 성능 시각화 및 논문용 자료 생성

### 6.2 품질 관리 체계

실험 품질 보장을 위한 다단계 검증 시스템을 운영한다.

검증 단계:

- **데이터 검증:** 전처리 데이터 무결성 확인
- **코드 검증:** 단위 테스트 및 통합 테스트
- **실험 검증:** 재현성 테스트 및 결과 일관성 확인
- **통계 검증:** 유의성 검정 및 효과크기 검증

## 7. 예상 결과 및 기여도

### 7.1 정량적 성과 예측

보수적 추정을 기반으로 한 예상 성능 개선 효과는 다음과 같다.

에너지 효율 예측:

- **크루즈 모드:** 4.2 km/kWh (기준선)
- **SAC from Scratch:** 4.8 km/kWh (14% 개선)
- **SAC Transfer Learning:** 5.1 km/kWh (21% 개선)

학습 효율성 예측:

- **수렴 속도:** 전이학습이 50% 빠른 수렴
- **샘플 효율성:** 전이학습이 50% 적은 데이터로 목표 성능 달성
- **안정성:** 전이학습이 30% 낮은 성능 분산

### 7.2 학술적 기여도

강화학습 분야 발전에 기여하는 주요 연구 성과는 다음과 같다.

방법론적 기여:

- 출퇴근 패턴 차이를 반영한 시간대별 강화학습 전략
- 전기차 도메인에 특화된 전이학습 방법론
- 26차원 확장 상태공간 설계 및 검증

실용적 기여:

- 실제 교통/기상 데이터 기반 현실적 시뮬레이션
- 클라우드 MLOps 기반 확장 가능한 실험 프레임워크
- 논문 게재급 완전 자동화된 성능 분석 파이프라인

## 7.3 산업적 응용 가능성

자율주행 및 전기차 산업에 직접 적용 가능한 기술적 성과를 도출한다.

응용 분야:

- **자율주행차:** 에너지 효율 최적화 제어 시스템
- **내비게이션:** 실시간 에코 라우팅 알고리즘
- **플리트 관리:** 상용차 연료비 절감 솔루션
- **정책 수립:** 친환경 교통 정책 의사결정 지원

이러한 체계적 방법론을 통해 과학적으로 엄밀하고 산업적으로 의미 있는 연구 성과를 달성할 수 있을 것으로 기대된다.